Примените обученную модель машинного обучения к неразмеченному сетевому трафику, выполните предобработку данных, сконструируйте признаки, интерпретируйте предсказания и проанализируйте выявленные аномалии.

Оформите решение в виде Jupyter Notebook. Итоговый ноутбук должен содержать программный код, выводы.

Исходные материалы:

- предобученная нейросетевая модель model.pkl;
- неразмеченный датасет traffic_unlabeled.csv;
- карта сервисов service_map.txt

Задание:

1. Загрузите датасет и проведите первичный анализ.

Выведите информацию о датасете (df.info()), проверьте:

1) количество строк и столбцов;
2) типы данных;
3) наличие пропусков;
4) примеры первых и последних строк.

2. Произведите предобработку данных

1) Преобразуйте timestamp в формат datetime.
2) Заполните пропуски:
   а) flags — пустой строкой и приведите к str;
   б) protocol — значением 'NONE' и приведите к str.
3) Выведите количество строк после обработки.

3. Сформируйте сервисы

1) Используйте словарь service_map, связывающий порты с названиями сервисов (ftp, ssh, http, https, dns и т.д.).
2) Создайте столбец service на основе dst_port. Для портов, которых нет в словаре, укажите 'other'.
3) Создайте столбец protocol_type, приведя protocol к нижнему регистру.

4. Постройте матрицу признаков X

Сформируйте признаки:

1) src_bytes — из bytes_sent;
2) dst_bytes — из bytes_received;
3) count — число записей для данного src_ip;
4) srv_count — число записей для пары src_ip + service;
5) same_srv_rate — отношение srv_count / count;
6) diff_srv_rate — 1 - same_srv_rate;
7) dst_host_count — число записей для данного dst_ip;
8) dst_host_srv_count — число записей для пары dst_ip + service;
9) serror_rate — доля записей с флагом SYN для данного src_ip;
10) rerror_rate — доля записей с флагом RST для данного src_ip;
11) protocol_type — категориальный признак;

12) service — категориальный признак;
13) duration — длительность соединения в секундах.

Приведите числовые признаки к float64, обработайте inf и nan, категориальные — к str.

5. Выведите предсказание и оценка уверенности

1) Выполните предсказание: pred = model.predict(X).
2) Добавьте в датасет столбец prediction.
3) Получите вероятности: proba = model.predict_proba(X).
4) Извлеките anomaly_score:
   а) для бинарной классификации — вероятность класса 1;
   б) для многоклассовой — максимальную вероятность.
5) Добавьте anomaly_score в датасет.

6. Проведите анализ результатов

1) Выведите распределение предсказаний (value_counts).
2) Рассчитайте средние значения признаков по классам: duration, bytes_sent, bytes_received, packets_sent, packets_received.
3) Выведите топ-20 наиболее подозрительных записей по anomaly_score.
4) Для аномальных записей вычислите: отношение bytes_sent / bytes_received; отношение packets_sent / packets_received.
5) Сравните эти отношения со средними значениями для класса «норма».

7. Сделайте выводы

1) Какие признаки сильнее всего отличают аномалии от нормы?
2) Почему аномальные сессии часто имеют малый объём принятых байт?
3) Что может означать сильная асимметрия «отправлено / получено»?
4) Какие типы атак или подозрительной активности могут соответствовать таким сессиям?

8. Сохраните работу в следующем виде: familia.ipynb

Необходимые приложения:

Файлы model.pkl, traffic_unlabeled.csv, service_map.txt

Файлы model.pkl, traffic_unlabeled.csv, service_map.txt, должны находиться локально у каждого участника.

Необходимые библиотеки:

1) pandas,
2) numpy,
3) joblib,
4) zlib,
5) gzip